

Análise Comparativa de Modelos LSTM, BiLSTM e GRU na Previsão de Dados Meteorológicos

Gabriele S. Araújo¹, Omar A. Carmona Cortes²

¹Departamento de Engenharia da Computação
Universidade Estadual do Maranhão – São Luís – MA – Brazil

²Instituto Federal de Educação, Ciência e Tecnologia do Maranhão (IFMA)

gabimitusa@gmail.com

Abstract. Modelos avançados de redes neurais, como LSTM, BiLSTM e GRU, têm se destacado em tarefas de previsão baseadas em séries temporais. Neste estudo é realizada uma análise comparativa do desempenho dessas arquiteturas na previsão de dados meteorológicos, utilizando métricas como MAE, MSE, RMSE e R^2 . Os resultados revelaram que todos os modelos apresentam desempenho consistente, sendo que a LSTM obteve o menor erro absoluto médio e quadrático médio, destacando-se para essa tarefa.

1. Introdução

Modelos de redes neurais recorrentes, do inglês *Recurrent neural networks* (RNNs) têm sido amplamente aplicados em problemas que envolvem séries temporais, como previsão de demanda, dados meteorológicos e sinais biomédicos [Rainio et al. 2024, Eom 2021, Desai 2020]. No entanto, RNNs tradicionais enfrentam desafios significativos ao lidar com dependências de longo prazo, primariamente devido ao problema de gradientes desaparecendo [Du et al. 2019].

Durante o treinamento de RNNs tradicionais, os gradientes tendem a se tornar exponencialmente menores quando propagados para trás através de múltiplas etapas de tempo. Esse fenômeno, conhecido como problema dos gradientes de desaparecimento (*Vanishing Gradient Problem*), resulta em duas limitações: informações de etapas iniciais da sequência se tornam progressivamente mais fracas e menos influentes e a rede neural tem dificuldade substancial em aprender e representar dependências de longo prazo [Fei and Tan 2018, Subramanian et al. 2023].

Para mitigar esses desafios, arquiteturas avançadas como *Long Short-Term Memory* (LSTM) [Toharudin et al. 2023], *Bidirectional LSTM* (BiLSTM) [Zhang and Thorburn 2022] e *Gated Recurrent Unit* (GRU) [Gao et al. 2019] foram desenvolvidas. Essas arquiteturas introduzem mecanismos de portão (gates) que permitem controlar precisamente como informações são armazenadas e descartadas, além de preservar informações relevantes por períodos mais longos e aprender dependências temporais complexas [Yu et al. 2019, Subramanian et al. 2023].

Como resultado, essas arquiteturas apresentam melhor desempenho em tarefas que requerem a captura de padrões temporais complexos, superando as limitações das RNNs tradicionais e expandindo significativamente suas capacidades de modelagem sequencial [Yu et al. 2019, Subramanian et al. 2023, Sabat et al. 2023]. Sendo assim, o objetivo deste trabalho é comparar o desempenho de LSTM, BiLSTM e GRU na previsão

de temperatura média diária com base em dados meteorológicos de Belém, Pará, coletados entre 2014 e 2024. Todo o código, os dados e as análises realizadas neste estudo estão disponíveis publicamente no repositório do GitHub¹, promovendo a transparência e possibilitando a reprodução e extensão dos resultados apresentados.

2. Materiais e Métodos

Nesta seção, são apresentados os materiais e métodos utilizados neste estudo, incluindo a descrição do conjunto de dados, o pré-processamento aplicado, as arquiteturas de redes neurais desenvolvidas, e as medidas de desempenho usadas para análise comparativa.

2.1. Conjunto de Dados

O conjunto de dados meteorológicos utilizado já foi aplicado em relatórios anteriores da disciplina para implementação com *Multilayer perceptron*. Retomando, esse *dataset* foi obtido do Instituto Nacional de Meteorologia (INMET) para a estação A201, localizada em Belém, Pará². As variáveis presentes incluem temperatura média, máxima e mínima, umidade relativa e precipitação diária. Tais dados foram coletados entre 1º de janeiro de 2014 e 31 de outubro de 2024, totalizando 3.870 registros.

2.2. Pré-processamento

Para garantir a consistência e a qualidade desses dados, foi aplicada uma interpolação linear para preencher valores ausentes, preservando a continuidade das séries temporais. Em seguida, foi utilizada a técnica de normalização *MinMaxScaler*, que transforma os valores das variáveis de entrada e saída para o intervalo [0,1], conforme a Equação 1. Essa abordagem é útil para evitar o impacto de escalas diferentes entre as variáveis [Sabat et al. 2023]:

$$P_{\text{normalizado}} = \frac{P - P_{\min}}{P_{\max} - P_{\min}} \quad (1)$$

onde P é o valor original, $P_{\text{normalizado}}$ é o valor ajustado, e $P_{\min}$ e $P_{\max}$ representam os valores mínimo e máximo da variável, respectivamente. Após a normalização, as séries temporais foram divididas em janelas de 30 passos temporais para alimentar os modelos, com um conjunto de treino e teste definido por validação cruzada com *5 folds*, respeitando a sequência cronológica dos dados.

2.3. Modelos e Configuração

Três arquiteturas de RNNs foram implementadas, cada uma projetada para capturar padrões temporais complexos em séries temporais:

Tabela 1. Arquiteturas RNNs

Modelo	Camadas	Neurônios por Camada	Função de Ativação
LSTM	2 LSTM, 1 Dens	100, 50, 25, 1	ReLU, Linear*
BiLSTM	2 BiLSTM, 1 Dens	100, 50, 25, 1	ReLU, Linear*
GRU	2 GRU, 1 Dens	100, 50, 25, 1	ReLU, Linear*

*Ativação Linear para regressão

¹<https://github.com/GabrieleAraujo/LSTM-BiLSTM-GRU-Comparison-.git>

²<https://bit.ly/48qC54D>

- **LSTM**: Redes projetadas para mitigar o problema de gradientes desaparecendo em RNNs tradicionais. As células LSTM utilizam portas de entrada, esquecimento e saída para preservar informações relevantes ao longo de sequências temporais extensas [Toharudin et al. 2023]. No modelo, foram incluídas duas camadas LSTM com 100 e 50 unidades, seguidas de uma camada densa.
- **BiLSTM**: Uma extensão do LSTM que processa informações em ambas as direções temporais (passado e futuro), capturando relações bidirecionais nas sequências [Zhang and Thorburn 2022]. Este modelo também utiliza duas camadas bidirecionais com 100 e 50 unidades, seguidas de uma camada densa.
- **GRU**: Uma arquitetura simplificada em relação ao LSTM, que combina as portas de entrada e esquecimento em uma única porta atualizada, reduzindo a complexidade computacional [Gao et al. 2019]. O modelo implementado inclui duas camadas GRU com 100 e 50 unidades, seguidas de uma camada densa.

Foi incluída em todas as camadas densas intermediárias a função de ativação *ReLU* (*Rectified Linear Unit*), enquanto as camadas de saída são lineares para fornecer previsões contínuas. Os modelos foram treinados por até 150 épocas utilizando o otimizador Adam, com taxa de aprendizado inicial de 0.005, e *batch size* de 64. Para mitigar o *overfitting*, foi aplicado *early stopping* baseado na perda de validação, com paciência de 10 épocas, e *dropout* de 20% para regularização.

2.4. Avaliação

Os modelos foram avaliados utilizando validação cruzada com 5 *folds* e as métricas de desempenho mais amplamente utilizadas: erro absoluto médio (*Mean Absolute Error - MAE*), erro quadrático médio (*Mean Squared Error - MSE*), raiz do erro quadrático médio (*Root Mean Squared Error - RMSE*) e coeficiente de determinação (R^2) [Wu et al. 2021, Ash and Shwartz 1999]. Essas métricas foram avaliadas conforme as Equações 2-5.

O **MAE** mede a média das diferenças absolutas entre os valores reais (Z_p) e os valores previstos (Z'_p), conforme a Equação 2:

$$MAE = \frac{1}{N} \sum_{p=1}^N |Z_p - Z'_p|, \quad (2)$$

onde N é o número total de amostras.

O **MSE**, definido pela Equação 3, penaliza mais fortemente os erros maiores devido à elevação ao quadrado das diferenças:

$$MSE = \frac{1}{N} \sum_{p=1}^N (Z_p - Z'_p)^2. \quad (3)$$

A **RMSE**, calculada conforme a Equação 4, é a raiz quadrada do **MSE**, sendo amplamente utilizada para avaliar a precisão de previsões em unidades comparáveis aos valores reais:

$$RMSE = \sqrt{\frac{1}{N} \sum_{p=1}^N (Z_p - Z'_p)^2}. \quad (4)$$

Por fim, o R^2 , definido na Equação 5, mede o quão bem o modelo captura a variação dos dados reais, variando de 0 a 1, onde valores mais próximos de 1 indicam maior precisão do modelo:

$$R^2 = 1 - \frac{\sum_{p=1}^N (Z_p - Z'_p)^2}{\sum_{p=1}^N (Z_p - \bar{Z})^2}, \quad (5)$$

sendo $\bar{Z}$ a média dos valores reais (Z_p).

3. Resultados e Discussão

Os resultados médios das métricas de desempenho obtidos ao longo dos 5 *folds* estão apresentados na Tabela 2. Para cada modelo, foram calculadas as médias e os desvios padrão das métricas *MAE*, *MSE*, *RMSE* e R^2 .

Tabela 2. Resultados Médios de *MAE*, *MSE*, *RMSE* e R^2 para LSTM, BiLSTM e GRU

Modelo	<i>MAE</i>	<i>MSE</i>	<i>RMSE</i>	R^2
LSTM	0.0299 ± 0.0014	0.0016 ± 0.0003	0.0399 ± 0.0037	0.3426 ± 0.0720
BiLSTM	0.0304 ± 0.0030	0.0017 ± 0.0004	0.0405 ± 0.0045	0.3190 ± 0.1078
GRU	0.0304 ± 0.0038	0.0016 ± 0.0004	0.0402 ± 0.0048	0.3335 ± 0.0835

A Tabela 2 apresenta os resultados médios das métricas de avaliação para os modelos LSTM, BiLSTM e GRU. O LSTM se destacou com o menor *RMSE* e maior R^2 , indicando maior capacidade preditiva para esse conjunto de dados. Não tão diferente, todos os outros modelos GRU e BiLSTM apresentaram resultados competitivos.

A fim de exemplo, para visualizar melhor a previsão desses modelos, nas Figuras 1, 2 e 3 são apresentadas as comparações das previsões dos modelos aos valores reais no *fold* 5.

De forma geral, os três modelos capturam bem os padrões gerais da série temporal, mas apresentam dificuldades em prever picos e vales extremos. Na Figura 1, o LSTM demonstra um bom alinhamento com os valores reais, mas apresenta erros maiores em eventos extremos. A Figura 2 mostra que o BiLSTM suaviza ainda mais as previsões, o que pode indicar uma dificuldade adicional em capturar variações locais bruscas. Já o GRU, conforme a Figura 3, apresenta previsões ligeiramente mais próximas dos valores reais, especialmente em regiões de variações moderadas, o que explica seu melhor desempenho nas métricas apresentadas na Tabela 2.

Em suma, apesar do bom desempenho geral, os modelos têm limitações na previsão de eventos extremos, possivelmente devido à normalização dos dados e à natureza não linear das séries meteorológicas. Assim como, o *Friedman test* (stat=0.4000,




Figura 1. Resultados das previsões para o modelo LSTM no 5 fold.




Figura 2. Resultados das previsões para o modelo BiLSTM no 5 fold.

$p=0.8187$) tenha indicado que não há diferenças estatisticamente significativas entre os modelos, os experimentos realizados demonstraram que arquiteturas avançadas de redes neurais como LSTM, BiLSTM e GRU são capazes de capturar padrões complexos em séries temporais meteorológicas.

4. Considerações Finais

Neste estudo foi realizada uma análise comparativa entre os modelos LSTM, BiLSTM e GRU na tarefa de previsão de temperatura média diária com base em dados meteorológicos da cidade de Belém, Pará, Brasil. O LSTM se destacou como a arquitetura mais eficiente, embora as diferenças em relação ao desempenho das demais arquiteturas tenham sido pouco expressivas. Tanto o GRU quanto o BiLSTM apresentaram resultados competitivos, reforçando que todas as arquiteturas avaliadas são adequadas para a previsão de séries temporais meteorológicas, com desempenho consistente nas métricas quantitativas e nos gráficos de previsão.

Para trabalhos futuros, sugere-se a aplicação de técnicas de otimização de hiperparâmetros, como busca em grade ou algoritmos genéticos, para explorar configurações mais adequadas para cada modelo. Assim como, investigar o impacto de incorporar variáveis climáticas adicionais e testar arquiteturas baseadas em *Transformers*, que têm mostrado resultados promissores em tarefas relacionadas a séries temporais.




Figura 3. Resultados das previsões para o modelo GRU no 5 fold.

Referências

- Ash, A. and Schwartz, M. (1999). R2: a useful measure of model performance when predicting a dichotomous outcome. *Statistics in medicine*, 18(4):375–384.
- Desai, C. (2020). Comparative analysis of optimizers in deep neural networks. *International Journal of Innovative Science and Research Technology*, 5(10):959–962.
- Du, S., Lee, J., Li, H., Wang, L., and Zhai, X. (2019). Gradient descent finds global minima of deep neural networks. In *International conference on machine learning*, pages 1675–1685. PMLR.
- Eom, S. H. (2021). Developing sentimental analysis system based on various optimizer. *International Journal of Internet, Broadcasting and Communication*, 13(1):100–106.
- Fei, H. and Tan, F. (2018). Bidirectional grid long short-term memory (bigridlstm): A method to address context-sensitivity and vanishing gradient. *Algorithms*, 11(11):172.
- Gao, B., Huang, X., Shi, J., Tai, Y., and Xiao, R. (2019). Predicting day-ahead solar irradiance through gated recurrent unit using weather forecasting data. *Journal of Renewable and Sustainable Energy*, 11(4).
- Rainio, O., Teuho, J., and Klén, R. (2024). Evaluation metrics and statistical tests for machine learning. *Scientific Reports*, 14(1):6086.
- Sabat, N. K., Pati, U. C., and Das, S. K. (2023). Abtcn: an efficient hybrid deep learning approach for atmospheric temperature prediction. *Environmental Science and Pollution Research*, 30(60):125295–125312.
- Subramanian, M., Rajalakshmi, V., et al. (2023). Deep learning approaches for melody generation: An evaluation using lstm, bilstm and gru models. In *2023 14th International Conference on Computing Communication and Networking Technologies (ICCCNT)*, pages 1–6. IEEE.
- Toharudin, T., Pontoh, R. S., Caraka, R. E., Zahroh, S., Lee, Y., and Chen, R. C. (2023). Employing long short-term memory and facebook prophet model in air temperature forecasting. *Communications in Statistics-Simulation and Computation*, 52(2):279–290.
- Wu, K., Wu, J., Feng, L., Yang, B., Liang, R., Yang, S., and Zhao, R. (2021). An attention-based cnn-lstm-bilstm model for short-term electric load forecasting in in-

tegrated energy system. *International Transactions on Electrical Energy Systems*, 31(1):e12637.

Yu, Y., Si, X., Hu, C., and Zhang, J. (2019). A review of recurrent neural networks: Lstm cells and network architectures. *Neural computation*, 31(7):1235–1270.

Zhang, Y. and Thorburn, P. J. (2022). Handling missing data in near real-time environmental monitoring: A system and a review of selected methods. *Future Generation Computer Systems*, 128:63–72.